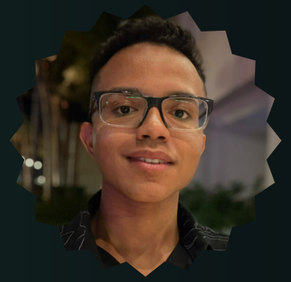
Software

NewsVerify IA



Gabriely



Moisés Lima



Romenia



Fabiano



James

Datasets

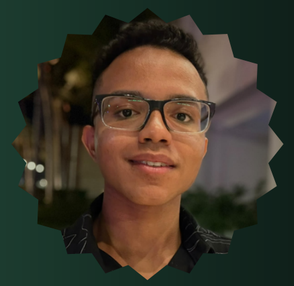
FakenewsBR

Base de notícias em português classificadas como verdadeiras ou falsas. Foi utilizada para fornecer exemplos de diferentes tipos de conteúdos e auxiliar o modelo a identificar padrões linguísticos associados à desinformação.

FakeRecogna

Dataset voltado à detecção de fake news, contendo informações classificadas para diferenciar conteúdos verdadeiros e falsos. Foi utilizado como uma segunda fonte de dados, aumentando a diversidade dos exemplos disponíveis para o modelo.

Análise Exploratória de dados (EDA)



Moisés de Lima Pereira

Engenharia de Software

Para que serve a Análise Exploratória de dados?



NewsVerify IA

Análise Exploratória de Dados (EDA)

Bibliotecas

Datasets



Conjunto estruturado de dados organizado para análise, treinamento de modelos ou geração de informações.

Pandas

Responsável por manipular e analisar os dados em formato de tabela.

Seaborn

Utilizado para criar gráficos e visualizar os dados.

Matplotlib

Também é utilizado para visualização e configuração dos gráficos.

Análise Exploratória de Dados (EDA)

Observações

```
dataset = load_dataset("recogna-nlp/FakeRecogna")
df = dataset['train'].to_pandas()

display(df.head())
```

```
Carregando o dataset FakeRecogna...
```

	Titulo	Subtitulo	Noticia	Categoria	Data	Autor	URL	Classe
0	\n\nPapa Francisco foi preso sob acusação de t...	Boato – Ocorreu um apagão no Vaticano. O papa ...	apagão vaticano papar presar acusação tráfico ...	entretenimento	11/01/2021	\nEdgard Matsuki	https://www.boatos.org/religiao/papa-francisco...	0.0
1	Equador prepara cova coletiva para mortos por ...	None	o governar equador anunciar preparar cova cole...	saúde	27/03/2020 18h25	27/03/2020 18h25	https://noticias.uol.com.br/internacional/ulti...	1.0
2	Air France voltará a operar voo direto Pequim-...	None	o companhia air france operar voar direto pequ...	saúde	07/08/2020 13h42	07/08/2020 13h42	https://www.uol.com.br/nossa/noticias/afp/2020...	1.0
3	Marfrig intensifica venda de carne do Brasil a...	None	o marfrig global foods retomar vender carnar b...	saúde	27/04/2020 14h53	27/04/2020 14h53	https://economia.uol.com.br/noticias/reuters/2...	1.0
4	As parciais das eleições de 2014 alternaram ma...	None	o assunto voltar o compartilhar rede social ju...	entretenimento	31/07/2021	Gilmar Lopes	https://www.e-farsas.com/as-parciais-das-eleic...	0.0

Observar a estrutura, quantidade de dados, colunas, tipos e identificar possíveis problemas.

Análise Exploratória de Dados (EDA)

Observações

```
# Quantidade de notícias verdadeiras e falsas
print("--- Quantidade de Notícias por Classe (0 = Falsa, 1 = Verdadeira) ---")
display(df['Classe'].value_counts())
```

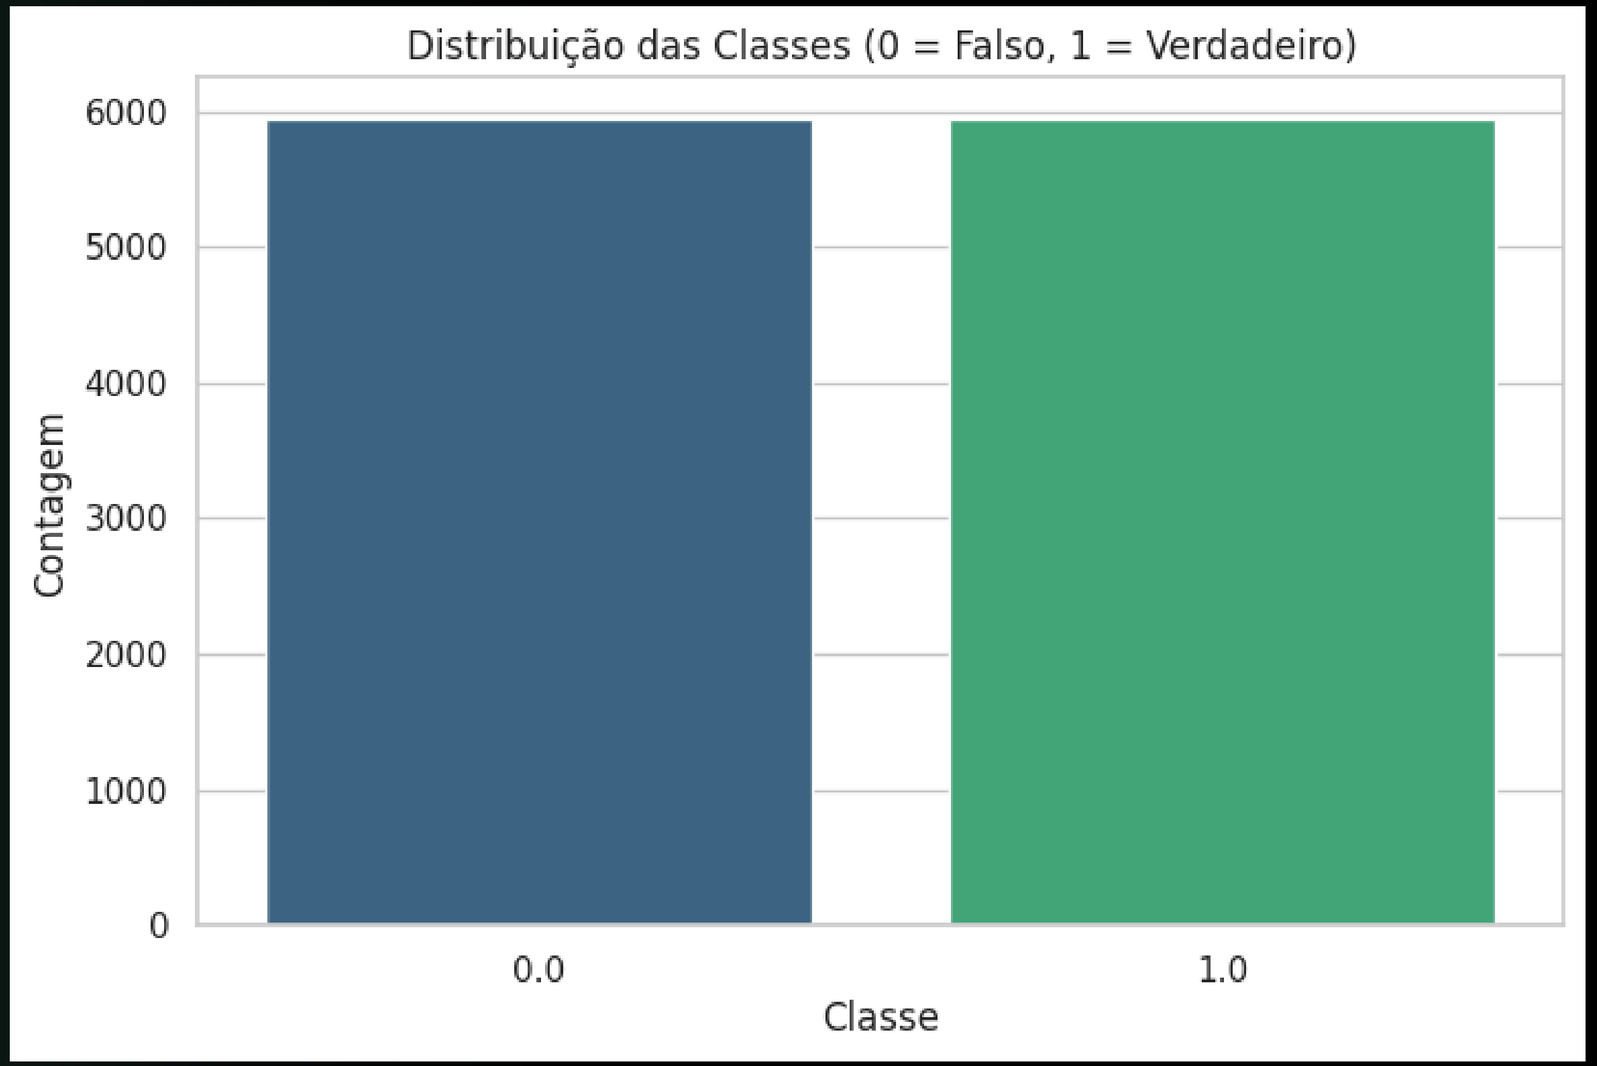
```
--- Quantidade de Notícias por Classe (0 = Falsa, 1 = Verdadeira) ---
```

Classe	count
0.0	5951
1.0	5951

Quantidade de notícias verdadeiras e falsas

Análise Exploratória de Dados (EDA)

Observações



NewsVerify IA

Análise Exploratória de Dados (EDA)

Observações

```
# Quantidade de notícias por categoria
print("\n--- Quantidade de Notícias por Categoria ---")
display(df['Categoria'].value_counts())
```

```
--- Quantidade de Notícias por Categoria ---
```

Categoria	count
saúde	4456
política	3951
entretenimento	1409
brasil	904
ciência	602
mundo	580

Quantidade de notícias por categoria

Análise Exploratória de Dados (EDA)

Saúde - 4456

Política - 3951

Entretenimento - 1409

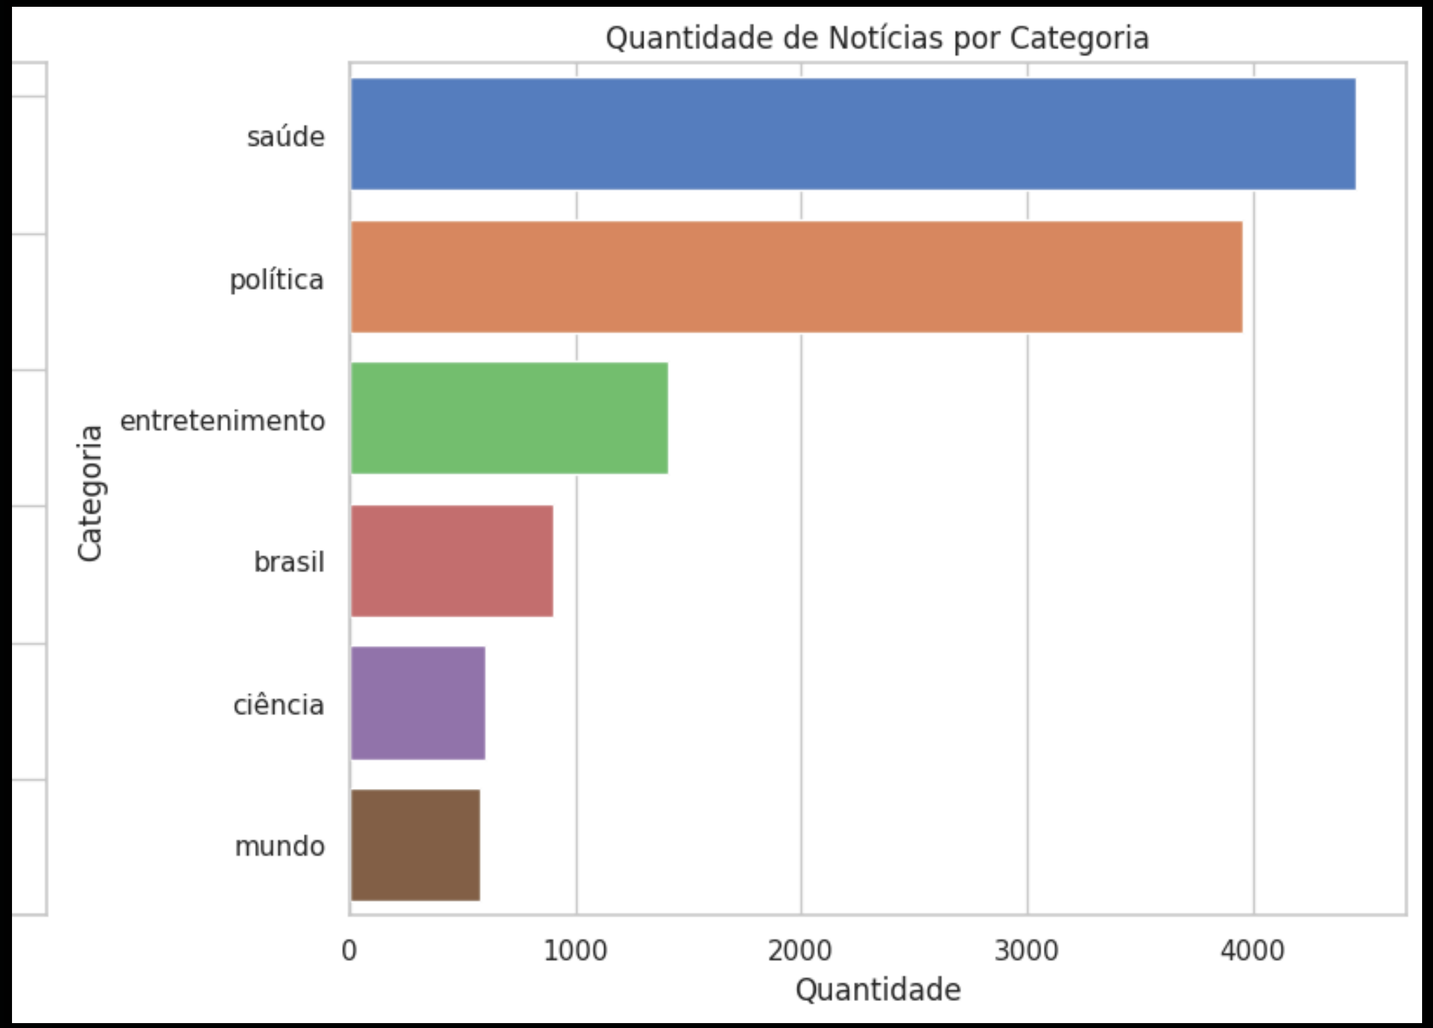
Brasil - 904

Ciência - 602

Mundo - 580

Observações

Geração de gráficos por cada categoria



NewsVerify IA

Análise Exploratória de Dados (EDA)

Observações

Extraindo informações da categoria “política”

```
# Filtrando o dataset para manter apenas as notícias da categoria 'política'
df_politica = df[df['Categoria'] == 'política'].copy()

print(f"Total de notícias de política: {len(df_politica)}")
display(df_politica.head())
```

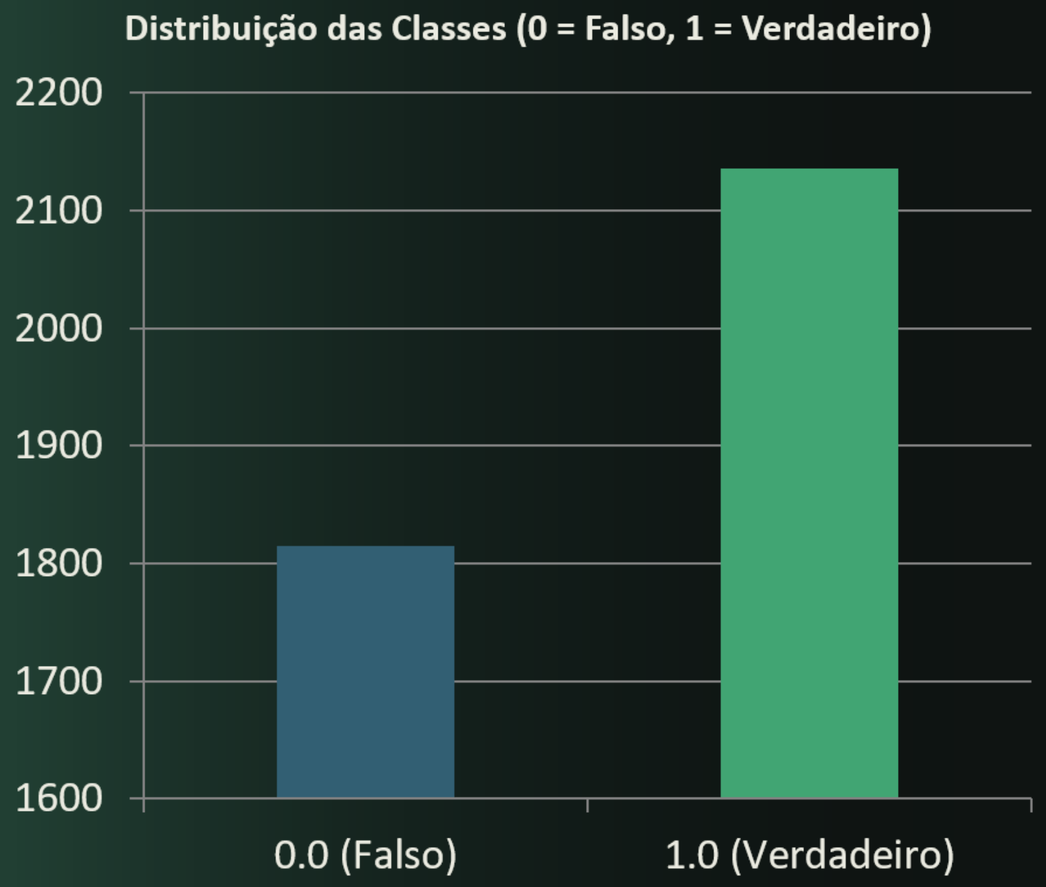
```
Total de notícias de política: 3951
```

	Titulo	Subtitulo	Noticia	Categoria	Data	Autor	URL	Classe
13	Após aglomeração na Libertadores, Palmeiras x ...	None	criticar liberar entrar maracanã convidar libe...	política	14/04/2021 10h50	14/04/2021 10h50	https://www.uol.com.br/esporte/futebol/colunas...	1.0
15	Freixo defende entrada do PSOL em bloco de Mai...	None	o deputar federal marcelo freixo psol-rj defen...	política	21/12/2020 18h25	21/12/2020 18h25	https://noticias.uol.com.br/colunas/leonardo-s...	1.0
17	\n\nMoro vai demitir 180 petistas que ganham m...	Boato – Bolsonaro passou o Coaf para o futuro ...	bolsonaro passar o coaf pro morar demitir peti...	política	10/12/2018	\nEdgard Matsuki	https://www.boatos.org/politica/moro-demitir-1...	0.0
19	É falso que o TSE atualizou apuração baseado e...	None	o tse fornecer informação apuração o site notí...	política	2020/11/20	Comprova	https://projetocomprova.com.br/publicações/e-f...	0.0
22	vídeo mostrar fraudar ocorrido urna eletrônica...	desde o início da tarde de hoje (29), circula ...	único publicação twitter vídeo obter visualiza...	política	29/11/2020	marco faustino	https://www.e-farsas.com/video-nao-mostra-frau...	0.0

NewsVerify IA

Total: 3951

Análise Exploratória de Dados (EDA) - Política



Análise do Equilíbrio em Política (3.951 registos)

Diagnóstico

Existe uma leve predominância de notícias verdadeiras (+321 registos), mas a proporção 54% / 46% é bem equilibrada para o treino dos modelos.

Classe 0.0 (Falsa) 1.815 notícias (45,94%).

Classe 1.0 (Verdadeira) 2.136 notícias (54,06%)

Tratamento de dados

Tratamento de dados

Observações

Remoção da coluna do “Autor”

Total de notícias de política: 3951

	Titulo	Subtitulo	Noticia	Categoria	Data	Autor	URL	Classe
13	Após aglomeração na Libertadores, Palmeiras x ...	None	criticar liberar entrar maracanã convidar libe...	política	14/04/2021 10h50	14/04/2021 10h50	https://www.uol.com.br/esporte/futebol/colunas...	1.0

```
# Removendo a coluna 'Autor'
df_politica = df_politica.drop(columns=['Autor'])

display(df_politica.head())
```

	Titulo	Subtitulo	Noticia	Categoria	Data	URL	Classe
13	Após aglomeração na Libertadores, Palmeiras x ...	None	criticar liberar entrar maracanã convidar libe...	política	14/04/2021 10h50	https://www.uol.com.br/esporte/futebol/colunas...	1.0
15	Freixo defende entrada do PSOL em	None	o deputar federal marcelo freixo	política	21/12/2020	https://noticias.uol.com.br/colunas/leonardo-s...	1.0

Tratamento de dados

Observações

Padronização coluna data AA/AA/AAAA

```
# Convertendo a coluna para datetime (lidando com formatos variados, priorizando dia primeiro)
df_politica['Data'] = pd.to_datetime(df_politica['Data'], errors='coerce', dayfirst=True)

# Formatando para Dia/Mês/Ano (DD/MM/YYYY)
df_politica['Data'] = df_politica['Data'].dt.strftime('%d/%m/%Y')

display(df_politica.head())
```

	Titulo	Subtitulo	Noticia	Categoria	Data	URL	Classe
13	Após aglomeração na Libertadores, Palmeiras x ...	None	criticar liberar entrar maracanã convidar libe...	política	14/04/2021	https://www.uol.com.br/esporte/futebol/colunas...	1.0
15	Freixo defende entrada do PSOL em bloco de Mai...	None	o deputar federal marcelo freixo psol-rj defen...	política	21/12/2020	https://noticias.uol.com.br/colunas/leonardo-s...	1.0
17	\n\nMoro vai demitir 180 petistas que ganham m...	Boato – Bolsonaro passou o Coaf para o futuro ...	bolsonaro passar o coaf pro morar demitir peti...	política	10/12/2018	https://www.boatos.org/politica/moro-demitir-1...	0.0
19	É falso que o TSE atualizou apuração baseado e...	None	o tse fornecer informação apuração o site notí...	política	NaN	https://projetocomprova.com.br/publicações/e-f...	0.0
22	vídeo mostrar fraudar ocorrido urna eletrônica...	desde o início da tarde de hoje (29), circula ...	único publicação twitter vídeo obter visualiza...	política	29/11/2020	https://www.e-farsas.com/video-nao-mostra-frau...	0.0

Tratamento de dados

Remoção de duplicatas

```
Registros iniciais: 3951
Registros removidos por possuírem Título repetido: 192
Registros removidos por possuírem URL repetida: 175
Total de registros removidos na limpeza combinada: 194
Total de registros restantes no dataset: 3757
```

	Titulo	Subtitulo	Noticia	Categoria	Data	URL	Classe
13	Após aglomeração na libertadores, palmeiras x ...	None	Criticar liberar entrar maracanã convidar libe...	Política	14/04/2021	https://www.uol.com.br/esporte/futebol/colunas...	1.0
15	Freixo defende entrada do psol em bloco de mai...	None	O deputar federal marcelo freixo psol-rj defen...	Política	21/12/2020	https://noticias.uol.com.br/colunas/leonardo-s...	1.0
17	\n\nmoro vai demitir 180 petistas que ganham m...	Boato – bolsonaro passou o coaf para o futuro ...	Bolsonaro passar o coaf pro morar demitir peti...	Política	10/12/2018	https://www.boatos.org/politica/moro-demitir-1...	0.0
19	É falso que o tse atualizou apuração baseado e...	None	O tse fornecer informação apuração o site notí...	Política	NaN	https://projetocomprova.com.br/publicações/e-f...	0.0
22	Vídeo mostrar fraudar ocorrido urna eletrônica...	Desde o início da tarde de hoje (29), circula ...	Único publicação twitter vídeo obter visualiza...	Política	29/11/2020	https://www.e-farsas.com/video-nao-mostra-frau...	0.0

Quais foram as dificuldades?

Notícias duplicatas



Impacto no Treinamento dos Modelos

Podem fazer o modelo memorizar exemplos específicos em vez de aprender padrões gerais.

Aumentam o risco de sobreajuste (overfitting).

Podem gerar métricas artificialmente elevadas, transmitindo uma falsa impressão de desempenho.

Em casos extremos, a mesma notícia pode aparecer nos conjuntos de treinamento e teste.

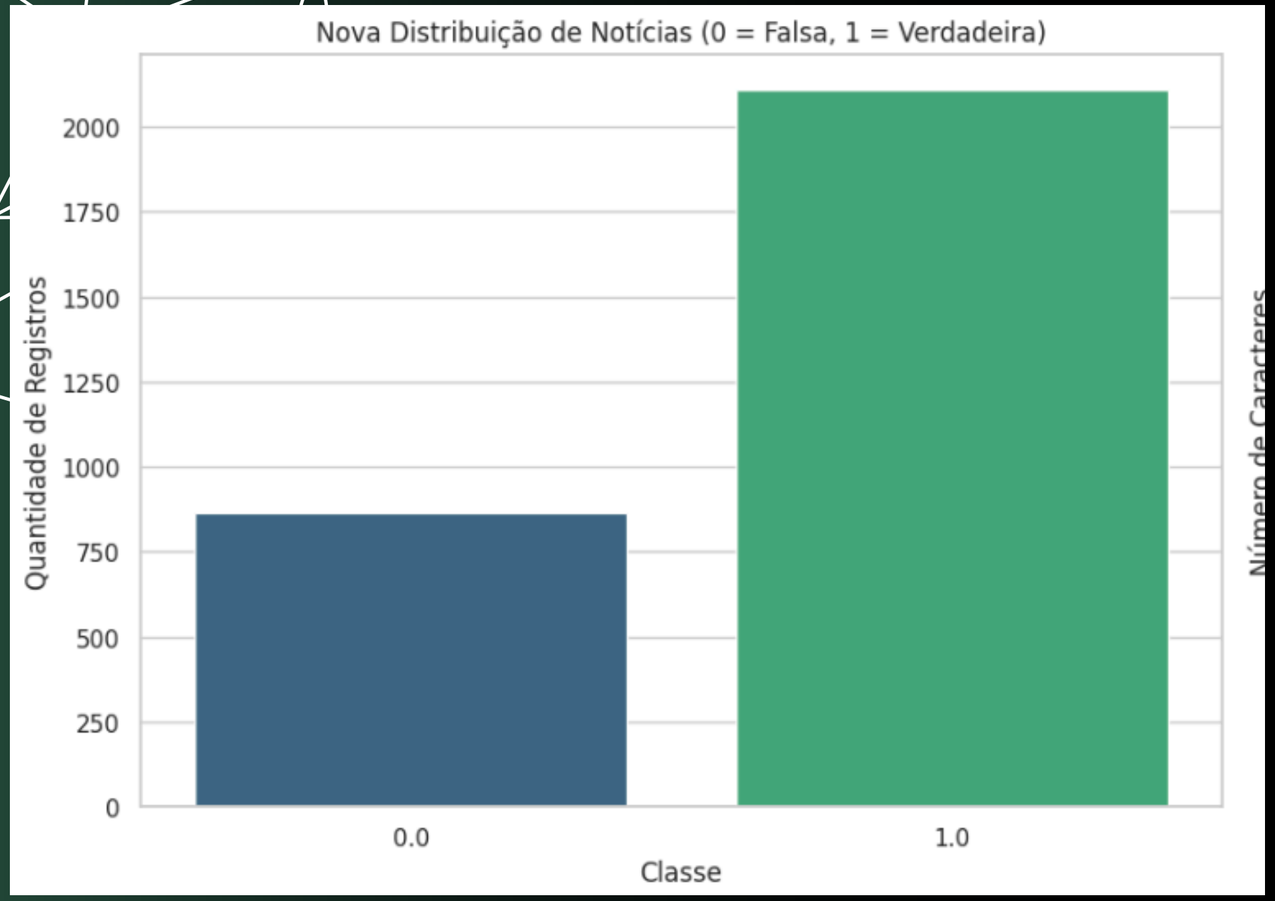
O modelo pode apresentar bons resultados apenas porque já teve contato prévio com aquele conteúdo.

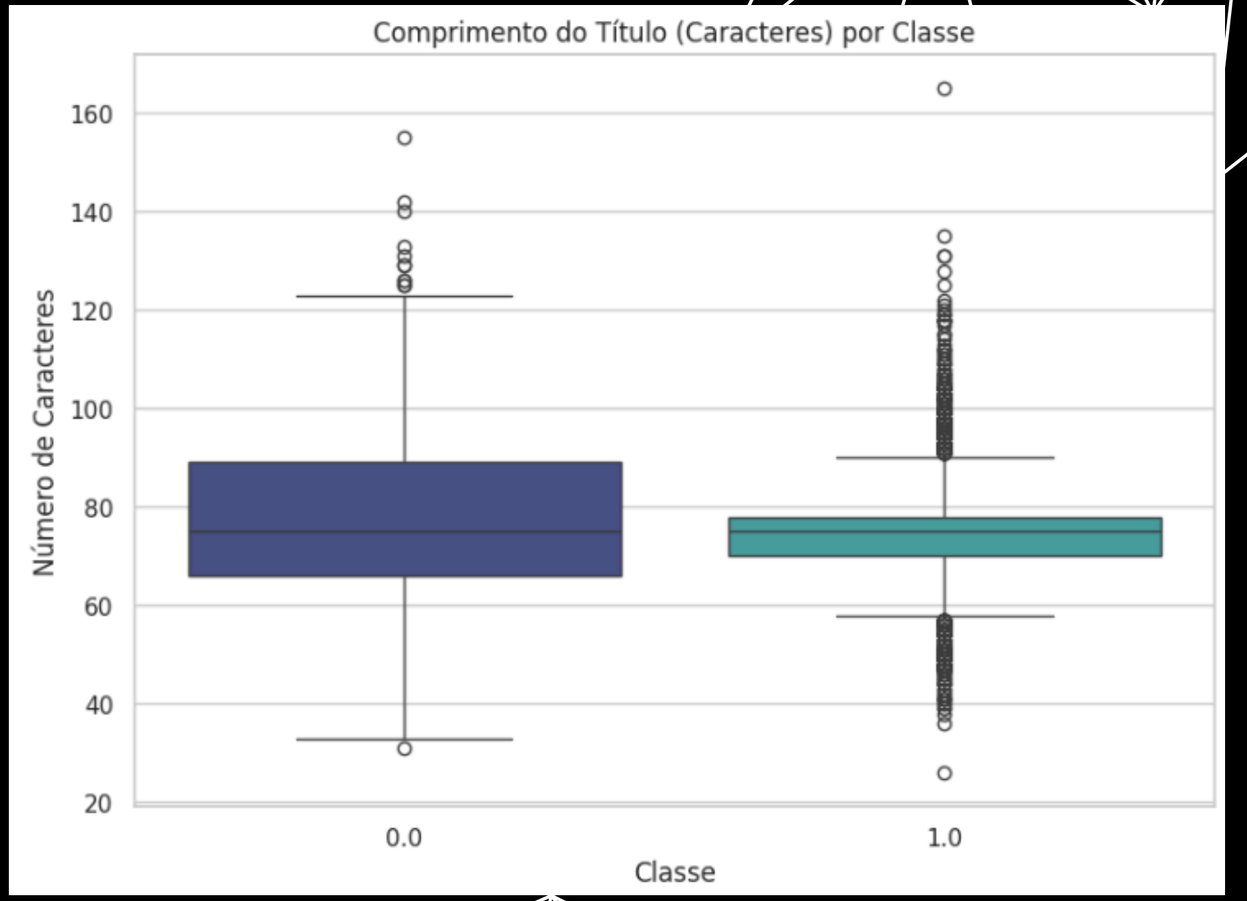


Objetivo

Após a limpeza dos dados, uma nova AED foi realizada para:

- Avaliar a qualidade da base tratada.
- Verificar os impactos das transformações aplicadas.
- Confirmar a consistência dos dados após o pré-processamento.
- Garantir que o conjunto de dados esteja adequado para as etapas de modelagem.





NewsVerify IA

Aprendizado Supervisionado



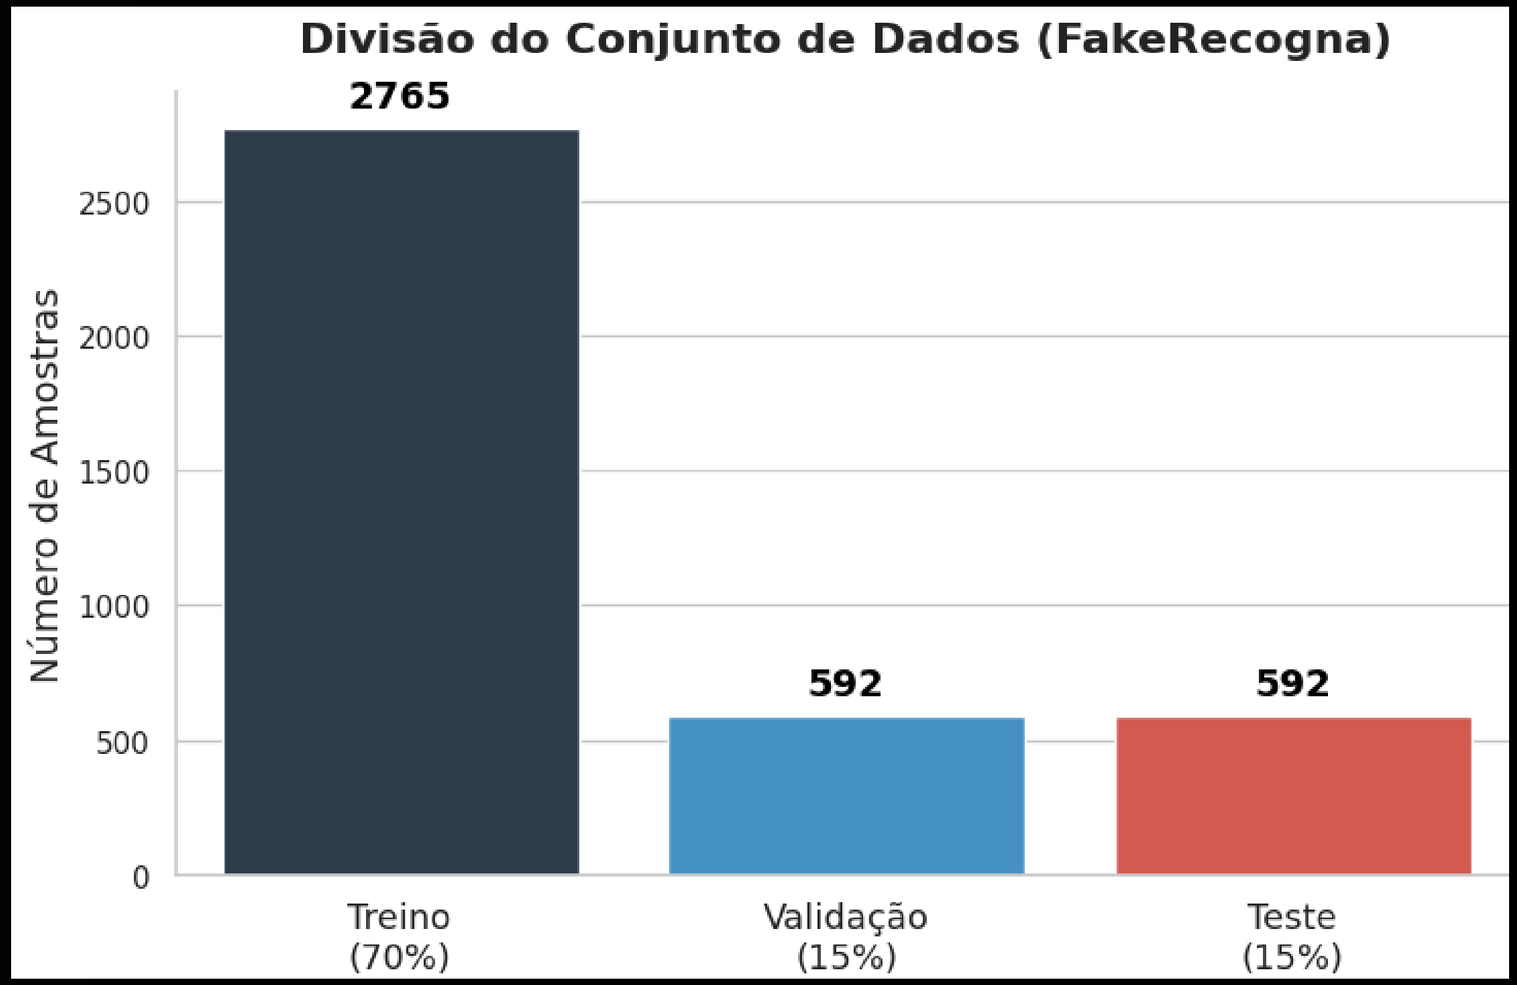
Douglas Salustiano

Engenharia de Software

Treino (70-80%)
Exemplos para o algoritmo aprender padrões.

Validação (10-15%)
Ajuste de parâmetros e prevenção de overfitting.

Teste (10-15%)
Avaliação final com dados inéditos



Comparativo de Modelos de Classificação

Árvore de Decisão (Decision Tree)

Vantagens

Explicável: Caminho lógico claro e regras bem definidas.

Fácil comunicação: Simples de explicar para leigos.

Dados brutos: Dispensa grande preparação ou normalização.

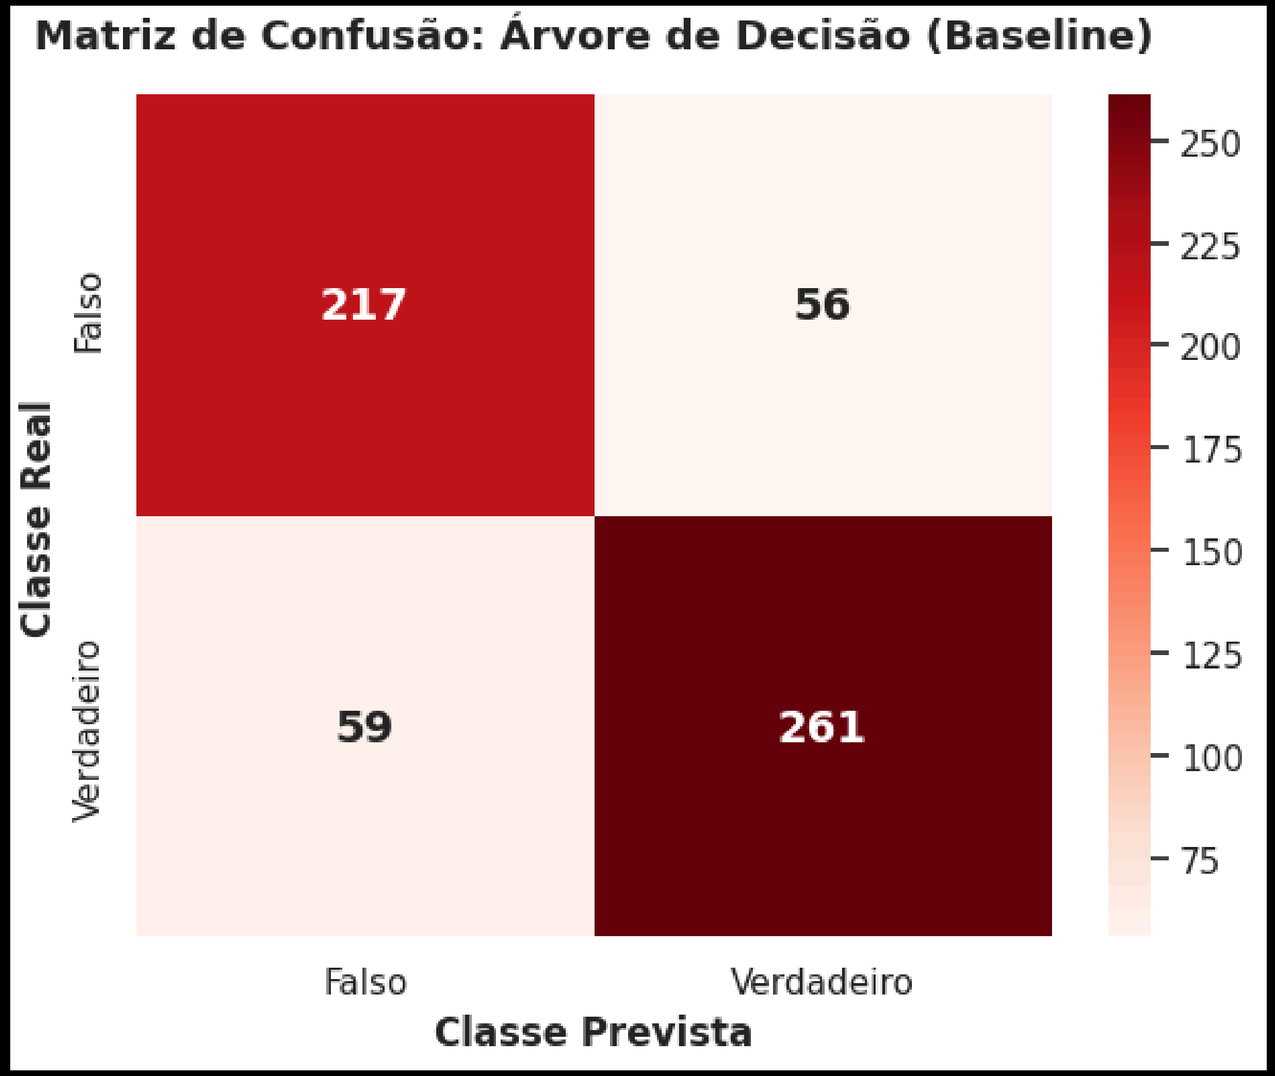
Desvantagens

Alta dimensionalidade: Ruim com grande volume de textos/colunas.

Overfitting: Instável; alta tendência a decorar os dados de treino.

Comparativo de Modelos de Classificação

Aplicação no Challenge (FakeRecogna)
Anomalias óbvias : Ideal para padrões muito claros (ex : tamanho de texto discrepante, excesso de pontuação ou repetição de palavras-chave).



NewsVerify IA

Comparativo de Modelos de Classificação

Nó Principal

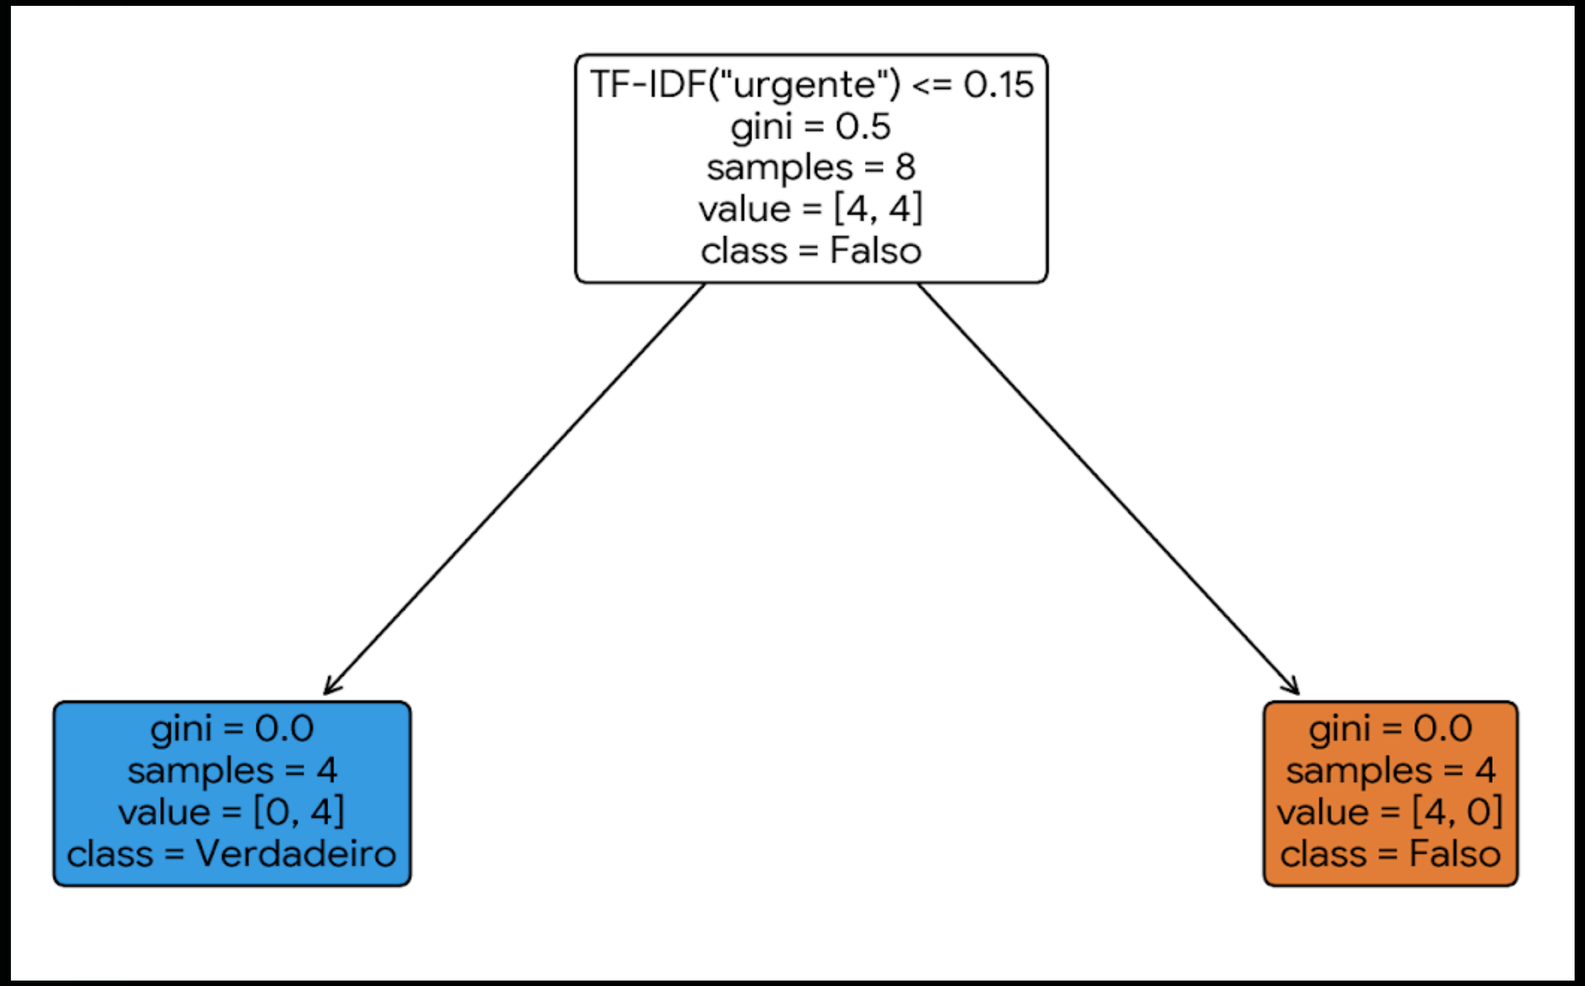
Faz a pergunta inicial, verificando se o peso da palavra "urgente" é maior que 0.15.

Ramos

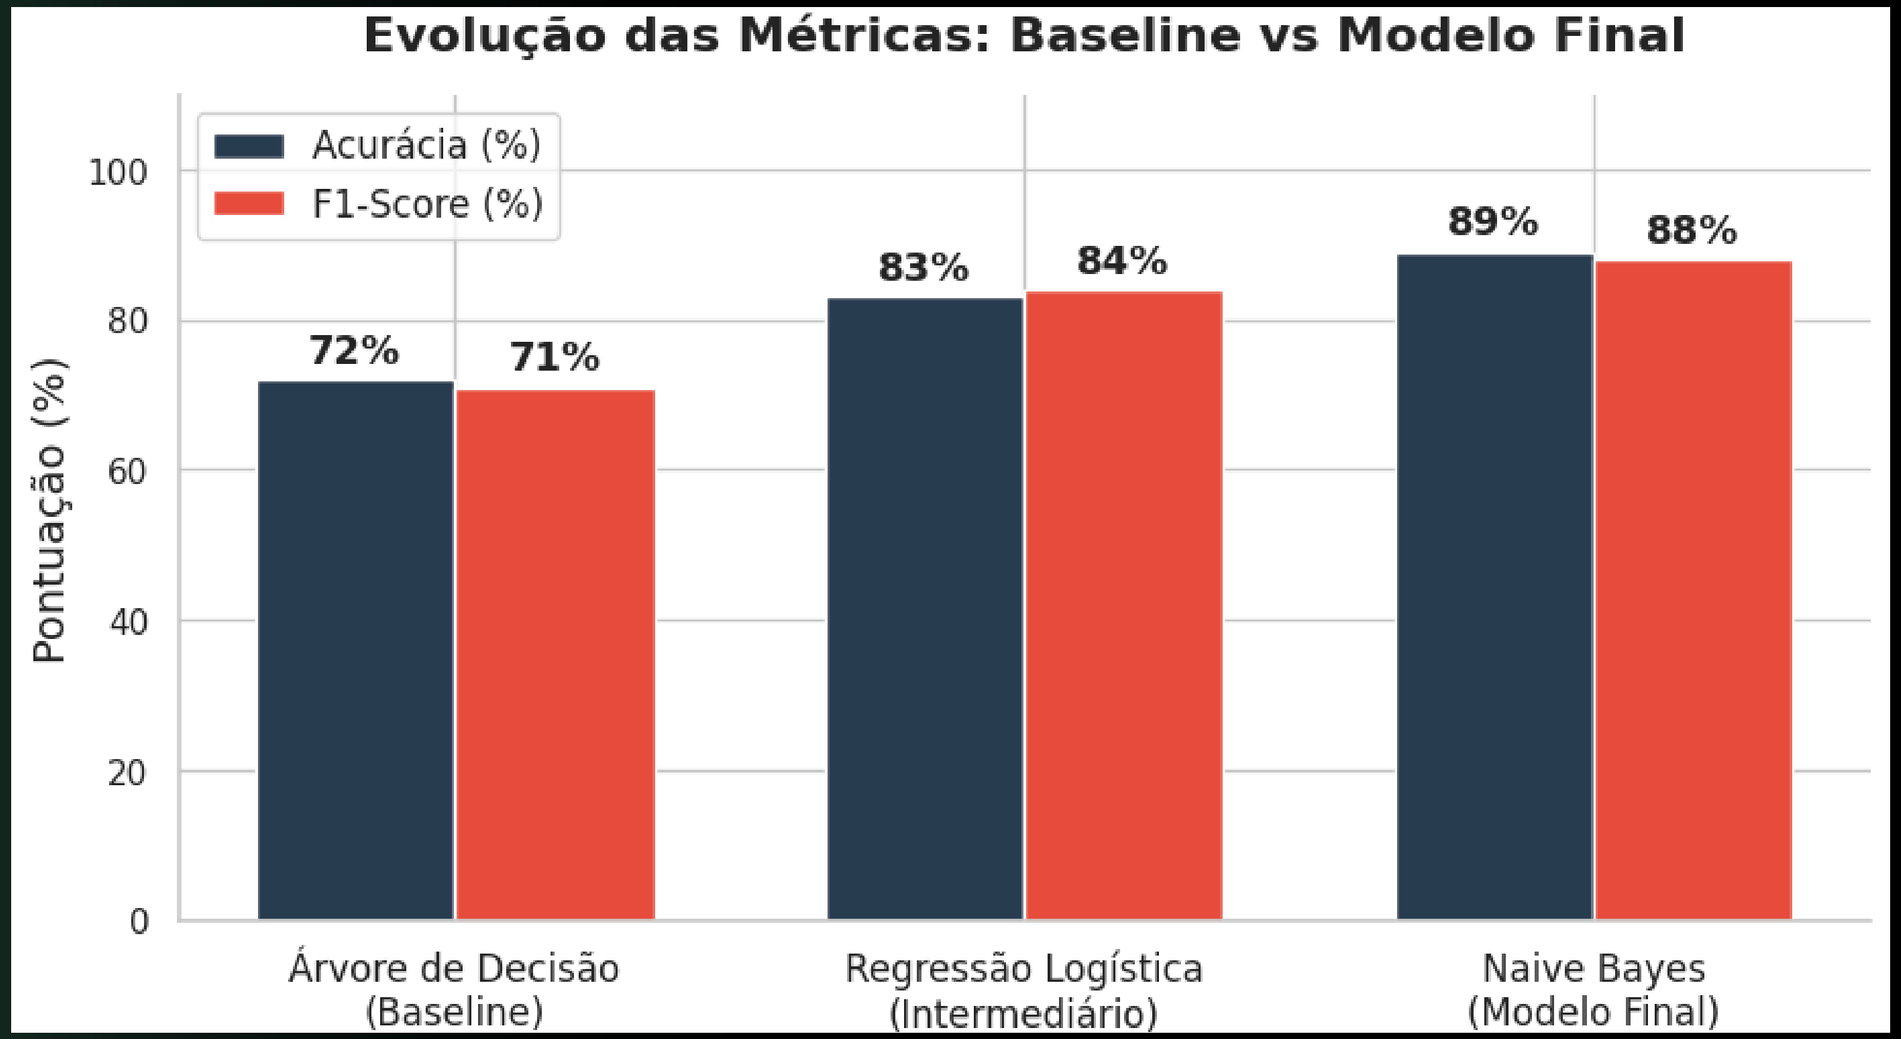
Direcionam o caminho do fluxo (esquerda para "Verdadeiro" e direita para "Falso").

Folhas

Apresentam o resultado final, classificando a notícia como Falsa (laranja) ou Verdadeira (azul).



Comparativo de Modelos de Classificação



NewsVerify IA

Regressão Logística (Logistic Regression)

Vantagens

Eficiente: Rápido, leve e fácil de implementar.

Interpretável:Atribui pesos às palavras explicadas.

Desvantagens

Modelo Linear: Falha em relações muito complexas.

Sem contexto : Não captura nuance de frases ou sarcasmo

Challenge (FakeRecogna)

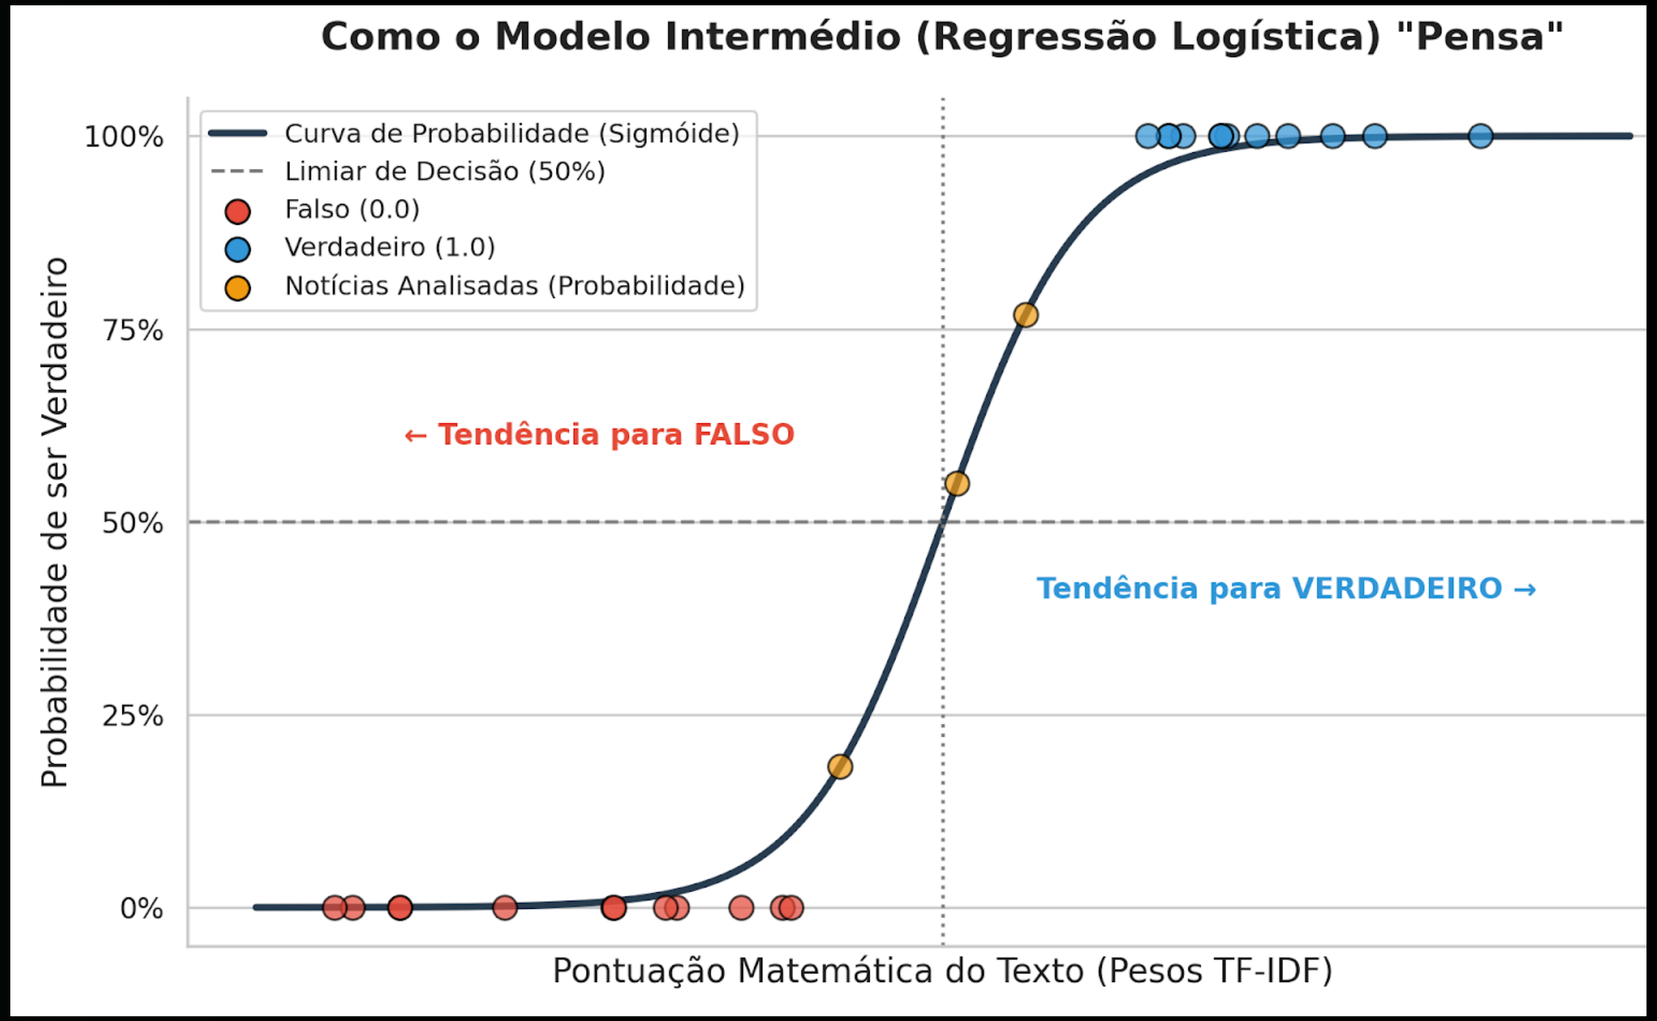
Separação Linear: Textos políticos vetorizados apresentam barreiras de classificação claras.

Análise de Probabilidade: Termos emotivos e nomes políticos elevam as chances de uma notícia ser falsa.

Regressão Logística (Logistic Regression)

Separação Linear
Textos políticos vetorizados apresentam barreiras de classificação claras.

Análise de Probabilidade
Termos emotivos e nomes políticos elevam as chances de uma notícia ser falsa.



NewsVerify IA

Naive Bayes

Vantagens

Alta Dimensionalidade:Funciona perfeitamente com vocabulários imensos .

Eficiente: Excelente performancee exige poucos dados de treino.

Desvantagens

Premissa "Ingênua": Assume que todas as palavras são totalmente independentes .

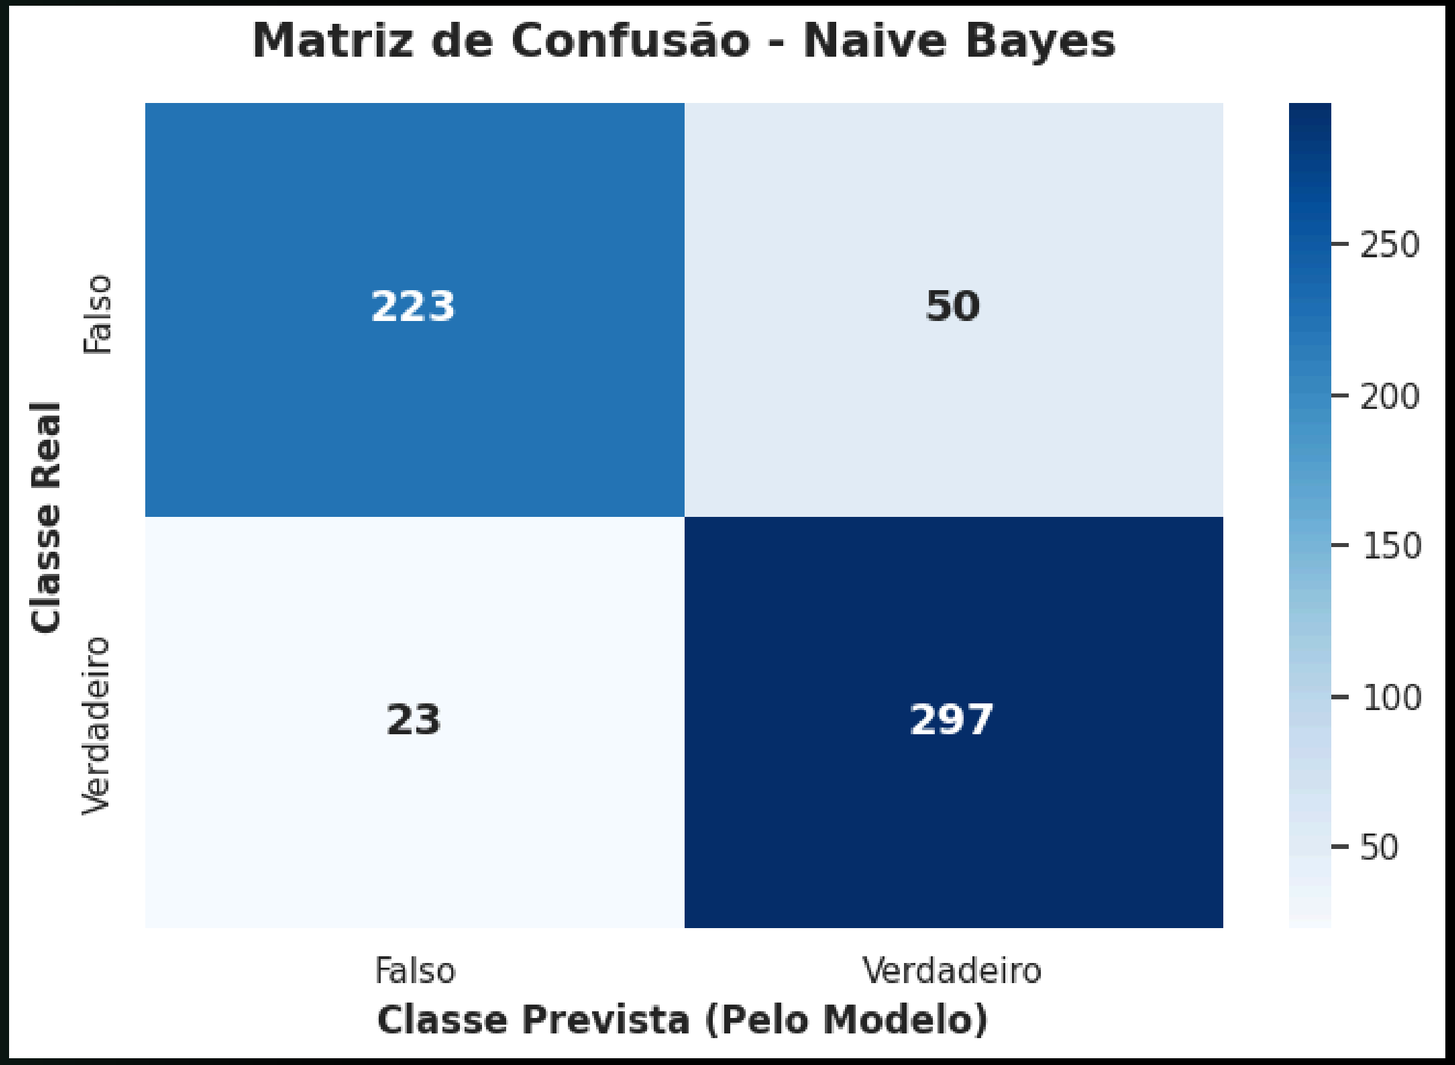
Sem Contexto: Ignora a ordem das palavras e o contexto semântico.

No Challenge (FakeRecogna)

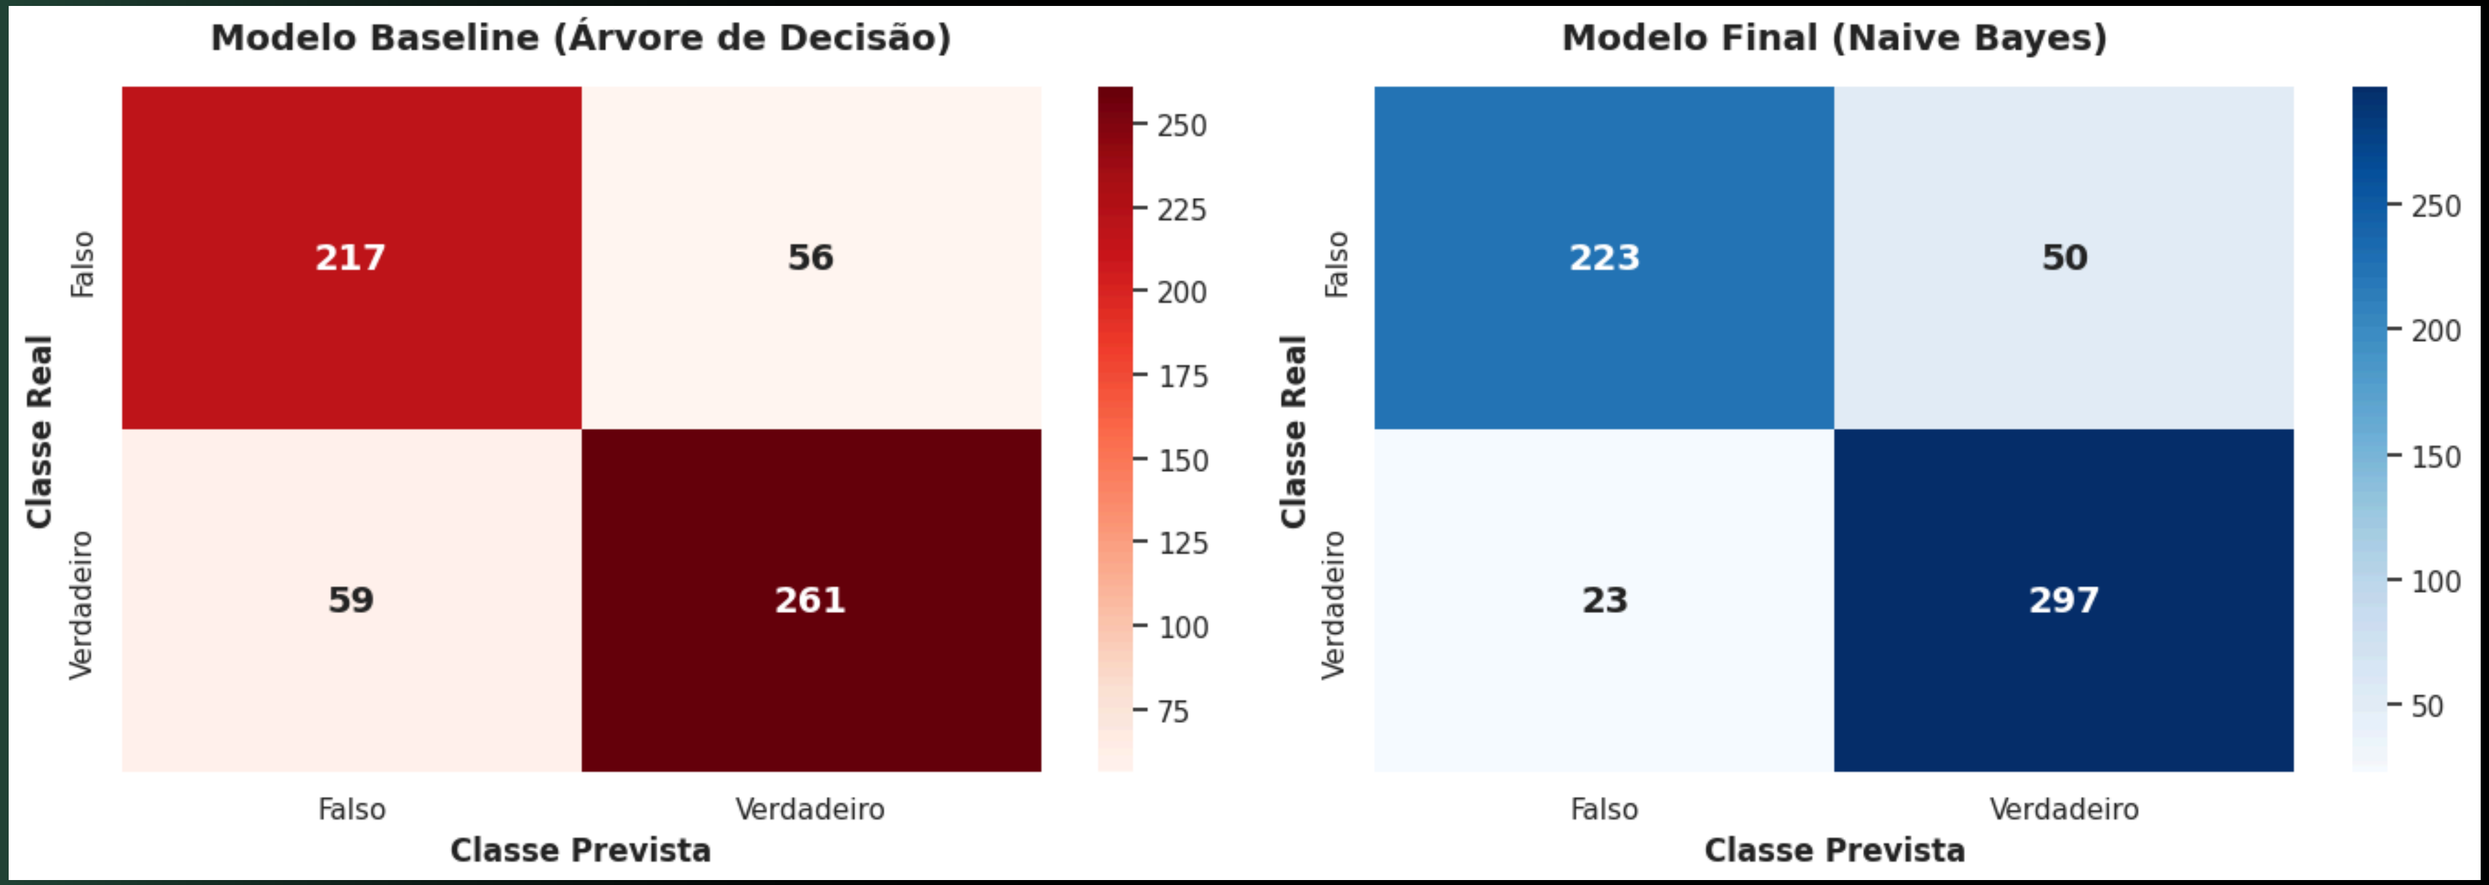
Frequência Estatística: Identifica notícias falsas pela probabilidade das palavras.

Amostras Menores: Desempenho brilhante na base com vetorização TF-IDF

Naive Bayes


Matriz de Confusão - Naive Bayes
Classe Real
Falso
Verdadeiro
223
50
23
297
250
200
150
100
50
Falso
Verdadeiro
Classe Prevista (Pelo Modelo)

Modelo Baseline vs.Modelo Final



NewsVerify IA

Evolução das Métricas (Do Baseline ao Modelo Final)

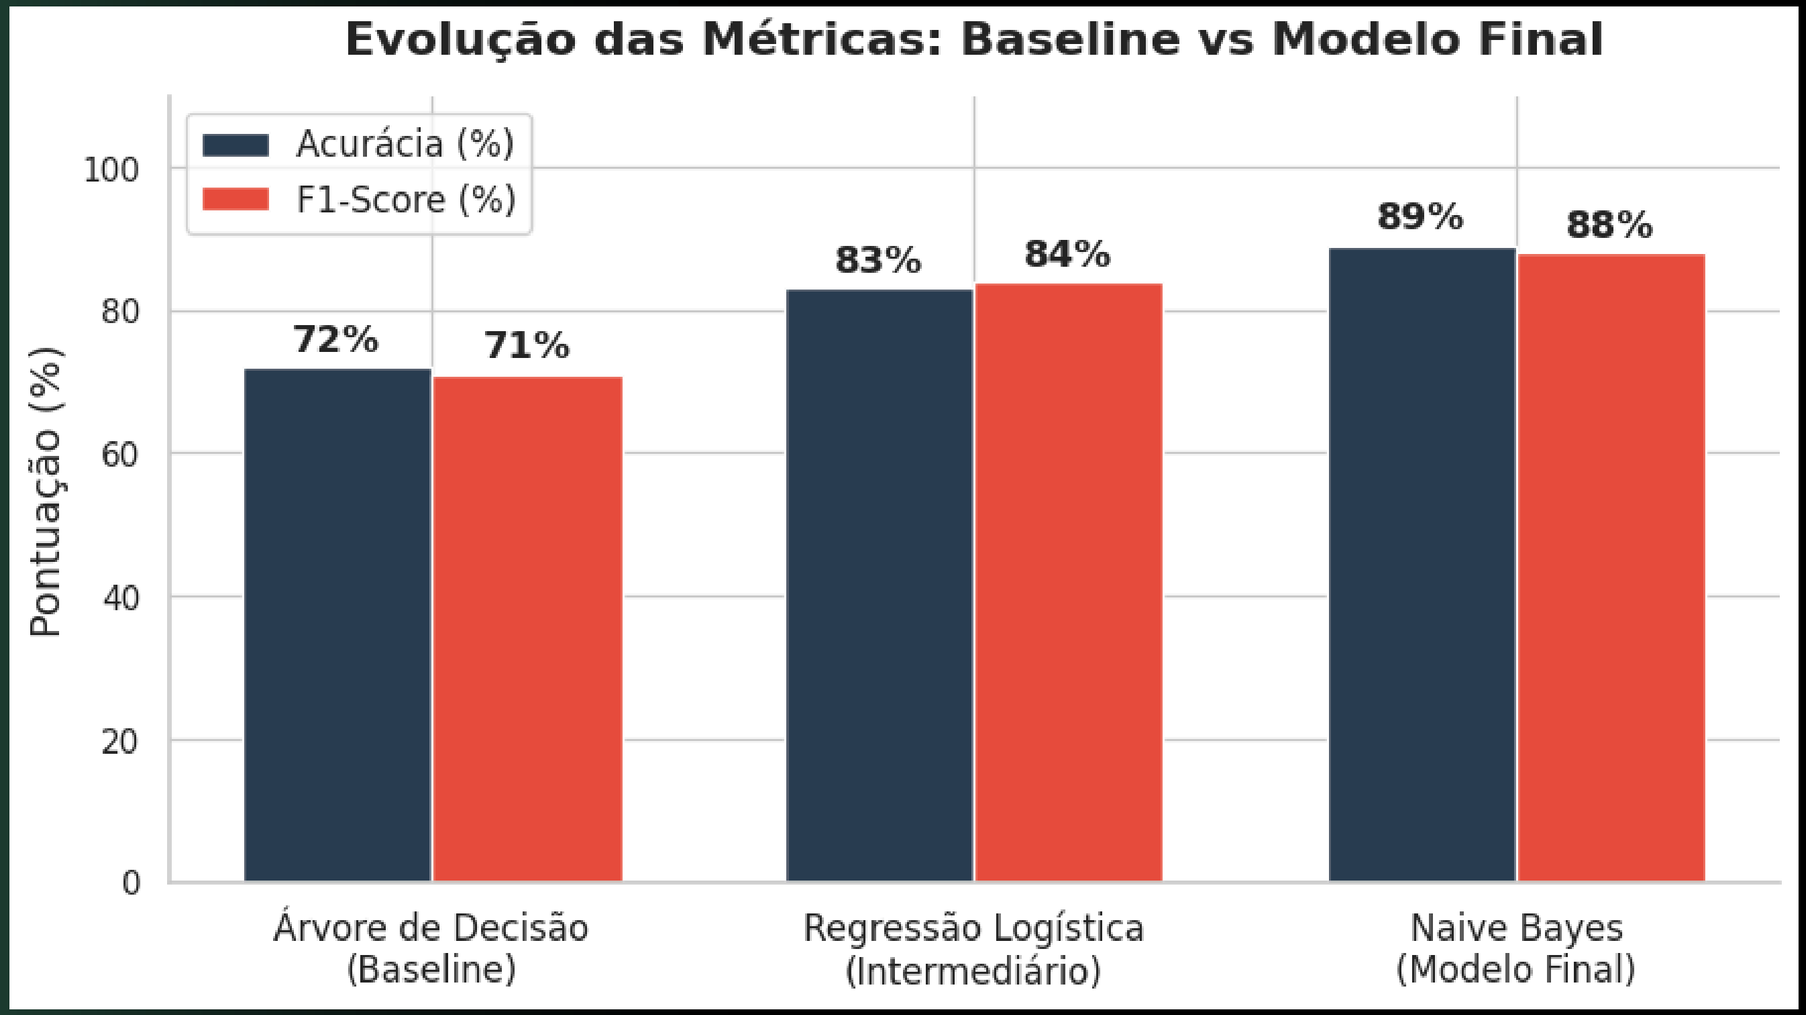
Métricas de Sucesso:
Base Balanceada (2.136 Verdadeiras / 1.819 Falsas).
Foco : Acurácia (acerto geral)
F1-Score (equilibrio entre Precisão e Recall).

Baseline: Árvore de Decisão
Acurácia: 70% a 74%
F1-Score: 71%
Comportamento: Alto overfitting
(100% no treino, cai para 72% no teste) devido a muitas ramificações .

Intermediário: Regressão Logística
Acurácia: 82% a 85%
F1-Score: 84%
Comportamento: Salto evidente de qualidade. Penaliza palavras irrelevantes e generaliza muito melhor.

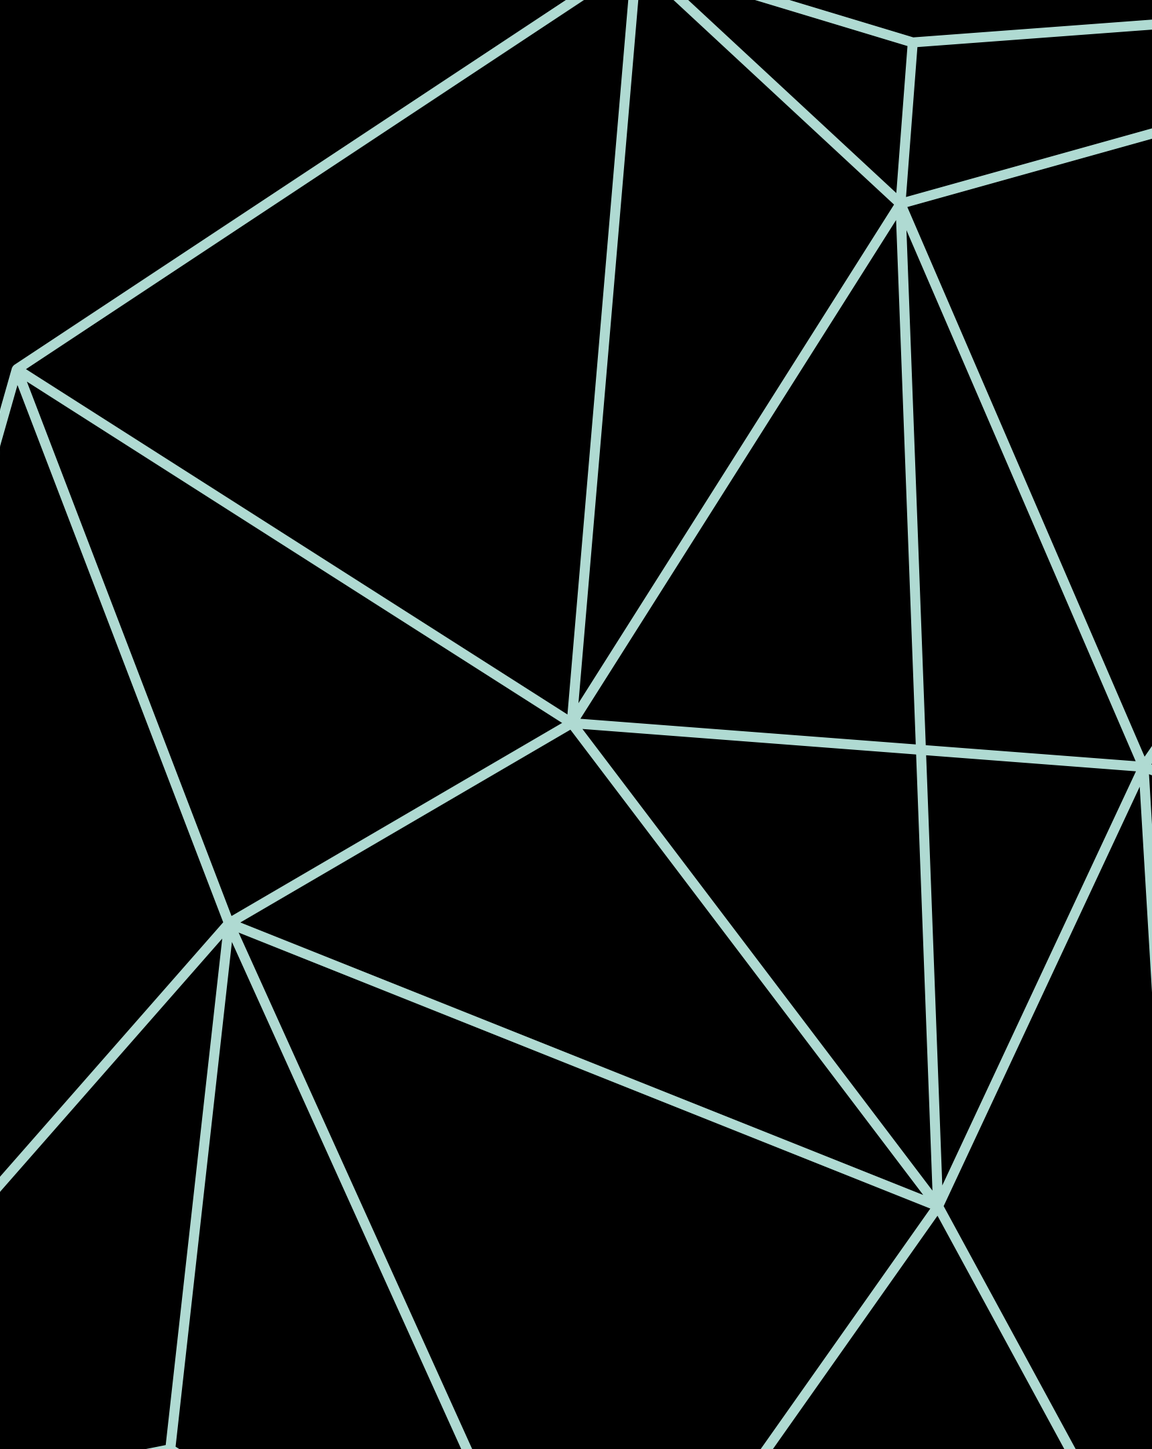
Modelo Final: Naive Bayes
Acurácia:87% a 91%
F1-Score:88% a 90%
Comportamento: Melhor performance geral. Calcula com precisão o peso estatístico (TF-IDF) e reduz falsos positivos.

Evolução das Métricas (Do Baseline ao Modelo Final)



NewsVerify IA

Aprendizado Não Supervisionado



3 Modelos

Isolation Forest

Detecta anomalias nos dados e é indicado para identificar registros atípicos, fraudes ou possíveis inconsistências em grandes conjuntos de dados.

DBSCAN

Agrupa registros semelhantes por proximidade e densidade, sendo útil para segmentação de dados e identificação de anomalias.

One-Class SVM

Identifica observações incomuns ao modelar apenas os exemplos considerados normais, sendo útil para detectar anomalias em conjuntos de dados.

DBSCAN

Quando é indicado utilizar?

-Descobrir grupos naturais nos dados sem definir previamente a quantidade de clusters.
-Detectar outliers ou observações isoladas.
-Trabalhar com conjuntos de dados que possuem clusters de formatos irregulares.

Vantagens

Não exige definir previamente o número de grupos (clusters)

- Diferentemente do K-Means, o DBSCAN identifica automaticamente quantos grupos existem nos dados.

Detecta outliers naturalmente

- Registros que não pertencem a nenhum grupo são classificados como ruído (noise), facilitando a identificação de anomalias.

Desvantagens

Sensível à escolha dos parâmetros

- O desempenho depende da definição adequada de eps (distância máxima) e min_samples (mínimo de pontos por grupo).

. Dificuldade com densidades muito diferentes

- Pode apresentar resultados insatisfatórios quando os clusters possuem densidades muito distintas entre si.

1. Não exige definir previamente o número de

DBSCAN

Porque funciona no nosso caso? (Challenge)

Adequado para este projeto porque permite identificar agrupamentos naturais de notícias semelhantes e detectar registros atípicos sem a necessidade de definir previamente a quantidade de grupos existentes nos dados.

One-Class SVM

Quando é indicado utilizar?

-Detecção de anomalias quando há poucos ou nenhum exemplo de casos anormais.
-Dentificação de fraudes, falhas ou comportamentos incomuns.
-Monitoramento de sistemas e análise de dados com eventos raros.

Vantagens

Eficiente para detectar anomalias complexas

- Consegue identificar padrões anormais mesmo quando a separação entre dados normais e anômalos não é linear.

Aprende apenas o comportamento normal

- Não necessita de exemplos de anomalias para treinamento, sendo útil quando os casos anômalos são raros ou desconhecidos.

Desvantagens

Sensível à escolha dos parâmetros

- O desempenho depende fortemente de parâmetros como nu e do tipo de kernel utilizado.

Alto custo computacional

- Pode apresentar baixa escalabilidade em datasets muito grandes, exigindo mais tempo e recursos de processamento.

One-Class SVM

Porque funciona no nosso caso? (Challenge)

É adequado para este projeto porque aprende o padrão normal das notícias e ajuda a identificar registros que apresentam características muito diferentes do comportamento predominante do dataset.

Isolation Forest

Quando é indicado utilizar?

Detecção de outliers

- Identificar registros muito diferentes do comportamento normal dos dados.

Limpeza de dados

- Encontrar observações que podem representar erros de coleta, preenchimento incorreto ou inconsistências.

Vantagens

Escalável para grandes volumes de dados

- Possui boa eficiência computacional e consegue processar grandes datasets de forma relativamente rápida.

Não requer dados rotulados

-

Desvantagens

Pode apresentar menor precisão em dados muito complexos

- Quando as anomalias são muito semelhantes aos registros normais, sua capacidade de detecção pode ser reduzida.

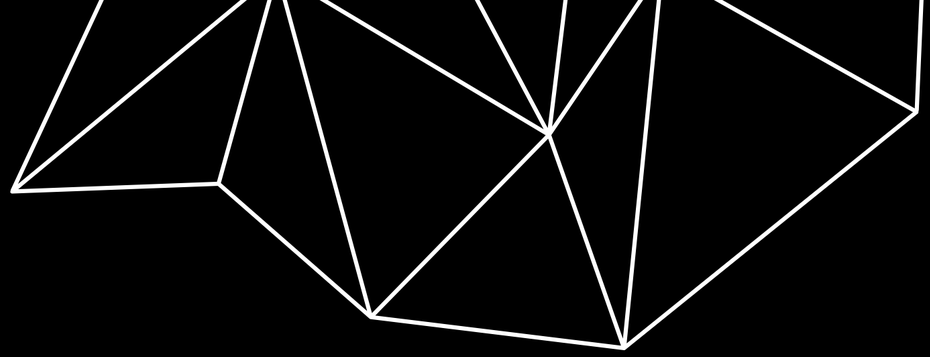
Sensível à proporção esperada de anomalias

- A configuração inadequada do parâmetro contamination pode impactar a qualidade dos resultados.

Isolation Forest

Porque funciona no nosso caso? (Challenge)

É adequado para este projeto porque identifica automaticamente notícias com características incomuns, auxiliando na detecção de outliers e possíveis inconsistências no dataset.



Obrigado!
Dúvidas?

